Tri-EvoBench L1-Life v2

成品状态与实际运行流程

项目组

2026 年 8 月 28 日

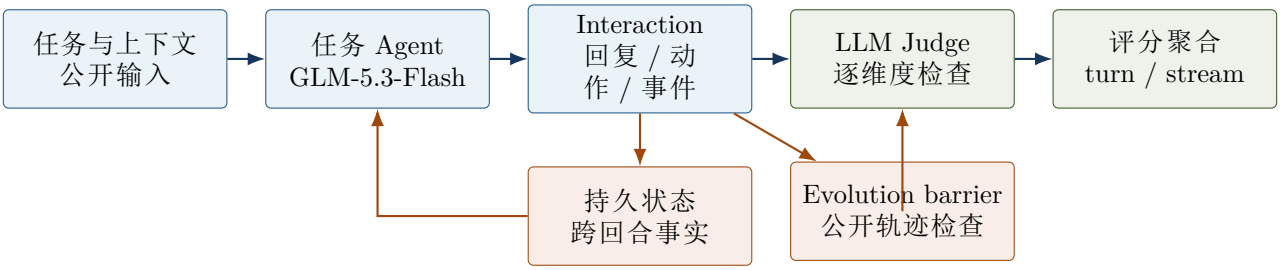
面向组会展示的成品报告：系统现在能做什么、一次评测如何流动、结果如何审计

120	124	270	0
完成 turns	可观测 interactions	模型 API calls	HTTP judge errors
两条流各 60	含 4 次重试	全量运行	最终运行

一句话结论 当前成品已经能够在 Docker 隔离环境中，把长上下文任务交给 LLM，连续执行多回合，并由独立 LLM judge 按任务成功、状态更新和交互质量进行逐回合评分；本次真实运行没有中断，但模型在 L1-Life 严格协议下的满分通过率仍为 0%，说明当前主要瓶颈是 agent 的任务完成与长期记忆行为，而不是评测链路不可用。

1 成品是什么

Tri-EvoBench L1-Life v2 是一个可重复的长上下文 agent 评测产品。它不只看模型最后一句话，而是把一次任务拆成可观察的回合，并保留任务输入、agent 回复、公开事件、状态变化、judge 裁决和最终分数。组会展示时，可以把它理解为一条带审计记录的流水线：



产品边界。 Judge 只看公开任务、公开 interaction 轨迹、允许检查的文件与工具结果；它不读取私有 oracle，也不能修改 sandbox。这样得到的分数既能反映模型是否完成任务，也能反映它是否正确使用状态和交互协议。

2 一次真实评测如何运行

1. 注入任务。每个 turn 提供一个真实的长上下文问题，可能要求摘要、比较、记忆回放或根据历史事实直接回答。
2. 生成回复。 GLM-5.3-Flash 在 Docker 中运行；agent 的自然语言回复和协议动作都被记录。
3. 形成 **interaction**。 Runner 记录当前 turn 的 request、raw response、events、actions、tool calls 和状态更新；必要时允许同一 turn 重试。

4. 独立裁决。 LLM judge 根据 rubric 对 task success、update precision、interaction quality 等维度打分，并给出失败原因。

5. 汇总成品指标。每条流输出 summary.json、trace.jsonl、状态快照和运行日志，可从 stream 级别回溯到单个 turn。



3 本次成品运行结果

运行配置为 Docker 隔离、Hermes 镜像 `trievo-hermes-merged:0.14`、GLM-5.3-Flash；两条独立流各执行 60 turns。为了让强制思考模型稳定完成长流，本次关闭了额外后台 review；演化 barrier 仍逐回合执行并留下 `skipped` 记录。因此这是完整的 60-turn benchmark 流，不是 smoke test，但不应被解释为开启后台演化的对比实验。

流	turns	interactions	API calls	平均分	成品观察
stream-1	60	62	131	0.1363	2,323,736 tokens；出现 2 次重试；无 judge HTTP 错误
stream-2	60	62	139	0.1524	2,501,417 tokens；出现 2 次重试；无 judge HTTP 错误
合计	120	124	270	0.1444	4,825,153 tokens；两个进程均正常退出



如何读 **0%** 通过率。这里的通过率是严格满分阈值，不是“有没有返回结果”。120 个 turns 都写入了 trace，judge 也完成了评分；但模型经常未完成任务、未触发所需状态更新，或在长回合中达到 iteration limit，所以只能得到部分分。这个结果揭示了成品当前的能力边界：评测框架能稳定暴露长期任务行为，但模型还没有稳定满足 L1-Life 的协议要求。

4 实际流程证据：一个 turn 从输入到裁决

以下证据直接来自 stream-2 的 turn 4，展示了成品如何把一个“记忆激活”问题变成可解释的评分，而不是只报一个总分。

1. 任务 **Agent request**

```
Without reopening earlier source material, what is my default response language
now? Answer directly and use the latest correction.
```

2. 任务 **Agent raw response**

Based on what I can currently access, your default response language is **English**.

To be transparent: the earlier exchange where a language ...

3. Judge 的逐维度结果

answer	1.0
memory_activation	0.0
no_stale_value	1.0
format	1.0

裁决： surface answer 正确，但没有可观察的事实检索，因此 activation 失败。

这个例子说明产品能够区分“答对了”与“以正确方式答对”：回答内容、格式和新旧值控制都通过，但长期记忆激活没有发生，所以总分为 0.75 且不判定为完整通过。

5 实际流程证据：失败也被结构化保留

stream-1 的 turn 1 是一个长上下文比较任务。模型理解了题意并展开了分析，但最后返回：

Turn 1 observable output

```
I reached the iteration limit and couldn't generate a summary.
```

Judge 因此标记 task success、update precision 和 interaction quality 失败，turn 分数为 0.10。这个记录对于组会展示很重要：系统没有把失败隐藏成“无输出”，而是保留了输入、模型事件、最终响应和失败维度。类似地，stream-1 的 turn 57 在延迟回放任务中明确表示无法检索历史，judge 标记 replay retention 失败，分数为 0.25。

观测点	模型行为	judge 解释	分数
turn 4 / stream-2	内容正确，未展示记忆检索	activation 失败，其余维度通过	0.75
turn 1 / stream-1	达到 iteration limit	任务未完成，状态未更新	0.10
turn 57 / stream-1	拒绝伪造延迟回放答案	replay retention 失败	0.25

6 成品现在具备的能力

能力	当前表现
长流运行	两条 60-turn 流均完整落盘，进程正常退出；不是单回合 smoke test。
公开轨迹审计	每个 turn 关联 request、raw response、events、actions、judge 结果和 feedback；可定位到失败维度。
跨回合评测	Judge 能看到当前 interaction 的轨迹，并对状态更新、记忆激活和延迟回放单独评分。
多维度分数	不把“回答正确”与“正确调用状态/交互协议”混为一谈，支持部分分。
可复现输出	每条流有 summary.json、trace.jsonl、状态快照和运行配置；结果可以二次分析。
安全边界	Judge 只读公开证据，不读取私有 oracle，也不具备修改 sandbox 的能力。

7 当前能力边界与下一步展示重点

- 模型侧瓶颈：长上下文任务中仍可出现 iteration limit；结构化动作和持久状态更新尚未稳定触发。
- 记忆侧瓶颈：模型有时给出正确表面答案，却没有通过可观察检索激活已存事实；延迟回放仍是主要失分来源。
- 演化侧说明：本次成品验收关闭了额外后台 review，以控制 GLM 长流耗时；barrier 仍记录，但本报告不宣称已完成演化收益验证。

- 推荐组会演示顺序：先展示流程图，再展示 turn 4 的 0.75 分解，最后展示两条 60-turn 汇总表。这样可以同时说明“链路跑通”和“为什么当前分数仍低”。

8 交付物与结论

本次交付的核心成品是可运行、可评分、可回放的 L1-Life v2 评测流，而不是单个静态回答。最终运行证据位于：

- `runs/l1-life-hermes-glm-final2/stream-1/l1_life_stream_1/`
- `runs/l1-life-hermes-glm-final2/stream-2/l1_life_stream_2/`

> 组会可直接使用的结论： Tri-EvoBench 已经把“长上下文 agent 是否真的完成任务”变成一条可重复的 Docker 产品流程。当前系统能稳定运行并解释失败；下一阶段的研究问题不再是“评测框架能不能跑”，而是“如何让 agent 在相同协议下稳定完成任务、激活记忆并产生结构化状态更新”。