Tri-EvoBench

Hermes、SkillOpt 与 Trace2Skill 的统一接入及真实评测状态

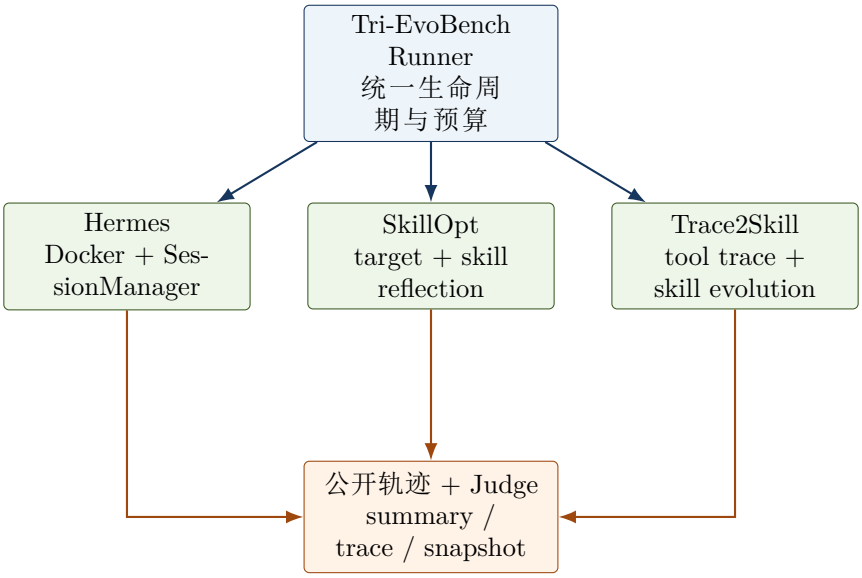
项目组

2026 年 8 月 28 日

统一运行协议下的三个 baseline：接入方式、真实任务轨迹与当前成品状态

Tri-EvoBench 当前已经不是单一 agent 的演示脚本，而是一层可以承载不同 agent 框架的评测运行时。Hermes、SkillOpt 和 Trace2Skill 都通过同一套 Flow/Turn/Interaction/Evolution 生命周期进入 Runner；差异保留在各自的 bridge 中，公共评测、公开轨迹、token 计量、状态快照和结果格式保持一致。

1 当前成品总览



三个 baseline 的统一输入输出关系如下：

层次	Hermes	SkillOpt	Trace2Skill
运行入口	Docker process adapter；复用 Hermes ACP SessionManager	独立 NDJSON bridge；调用 target backend	独立 NDJSON bridge；运行 CLIOnly/CLISkillPreloaded agent
工作区	共享 `/workspace`；状态挂载 `/hermes-state`	共享 workspace；Flow 独占 `skill.md` 与 `history/`	共享 workspace；Flow 独占 `skills/` 与 `history/`
学习阶段	Hermes background/native review 或 barrier 记录	Reflect -> Aggregate -> Clip -> Update	MAP -> REDUCE -> APPLY -> VERIFY
输出轨迹	回复、模拟工具、事件、状态更新、judge	回复、`write_file` action、skill hash、usage	回复、真实 tool calls、步骤 trace、skill/evolution 文件

2 统一接入方式

每个 baseline 都实现同一组生命周期方法。Runner 不需要理解某个框架内部的 session、skill 或工具实现，只消费 bridge 返回的结构化结果。

1. **initialize**：校验 protocol version，声明 capabilities，并读取 manifest 中的环境与运行参数。
2. **start_flow**：创建 Flow 独占的状态目录和共享 workspace，装载初始 skill/memory，并返回状态快照信息。
3. **start_turn**：建立新会话；Turn 不继承聊天 history，但继续使用同一 Flow 的学习状态。
4. **interact**：将一次 benchmark 请求翻译成框架原生调用，返回最终文本、公开 tool/action 轨迹、事件和增量 usage。
5. **evolve**：只接收公开 trajectory 与公开 judge feedback；完成后才能进入下一 Turn。
6. **snapshot/end_flow**：对声明的学习状态做 hash 和 diff，导出 summary、trace、快照，清理临时配置与 session 数据库。

> 关键隔离边界：`verifier_details`、`oracle_update`、私有 evaluator 文件和私有 metadata 不进入 baseline bridge。Judge 能看到的是公开任务、公开交互和允许检查的文件；因此不同 baseline 的分数在同一可见性边界下可比较。

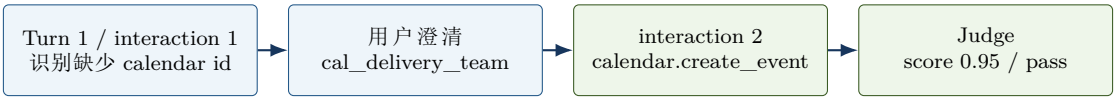
3 Hermes：从上游 Session 到 Tri-EvoBench Flow

Hermes 的接入保留上游能力，同时把外层生命周期交给 Tri-EvoBench：

- manifest 启动受限 Docker 容器，挂载共享 workspace 和 Flow 状态目录，并通过环境白名单透传模型凭据；
- bridge 直接复用 Hermes 的 SessionManager、AIAgent、SessionDB 和工具集，不要求 Runner 理解 ACP；
- L1 通过协议 action/event 记录副作用，L2 保留 native private verifier 边界；
- 每个 Turn 结束后进入 evolution barrier，Runner 记录学习状态变化与 token usage。

真实 Hermes L1 运行：一个 Turn 的完整闭环

在 `runs/merge-hermes-l1-full-final/` 的 7-turn 真实运行中，第一轮展示了澄清、重试和工具调用如何串起来：



第一轮的可观察字段为：

- 初次回复触发 `asked_for_calendar_id`，没有在不确定时直接创建事件；
- 澄清后调用 `calendar.create_event`，参数包含 `calendar_id=cal_delivery_team`、标题 `Aurora` 周例会、时间 `2026-08-24 10:00-10:30 +08:00`；
- Judge 对任务完成、工具参数、记忆事实和回复语言分别评分，最终 0.95，唯一扣分是澄清事实没有在创建前以可观察状态再次记录。

同一运行的后续真实经历包括：Turn 2 首次未执行文件和群组动作，重试后产生风险清单文件并修正群组 ID；Turn 5 首次未写入润色文件，重试后生成 `docs/abstract_polished.txt`；Turn 6 生成中文摘要文件。最终 7 turns、13 interactions，平均分 0.9214，turn 通过率 100%。这说明 Hermes 接入已经能把“失败 -> feedback -> retry -> action -> judge”完整保留下来。

Hermes 长流压力结果

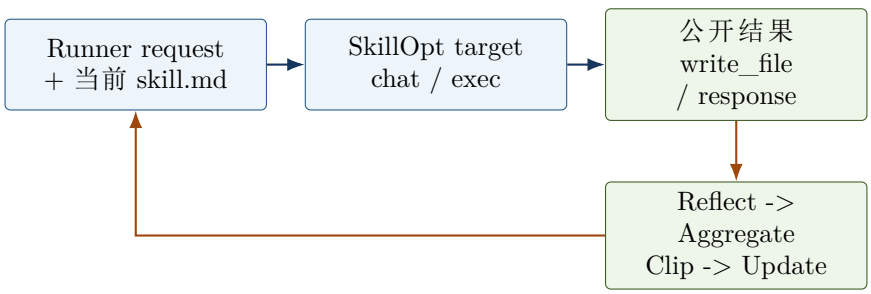
GLM-5.3-Flash 下的两条 60-turn L1-Life v2 流进一步验证了长流成品：

流	turns	interactions	API calls	平均分	严格通过率
stream-1	60	62	131	0.1363	0%
stream-2	60	62	139	0.1524	0%
合计	120	124	270	0.1444	0%

所有 turns 均落盘且 judge 请求无 HTTP 错误；低分来自 iteration limit、未触发记忆激活和未完成结构化任务。该长流结果与上面的 7-turn 成功链路共同说明：运行时接入和审计链路已稳定，长期任务完成能力仍是独立的模型问题。

4 SkillOpt：把 target agent 与 skill 更新接入同一 Flow

SkillOpt bridge 的职责是把 Tri-EvoBench 的 Interaction 请求交给 target backend，把公开反馈交给 skill 优化流程，并把学习状态限制在 Flow 目录：



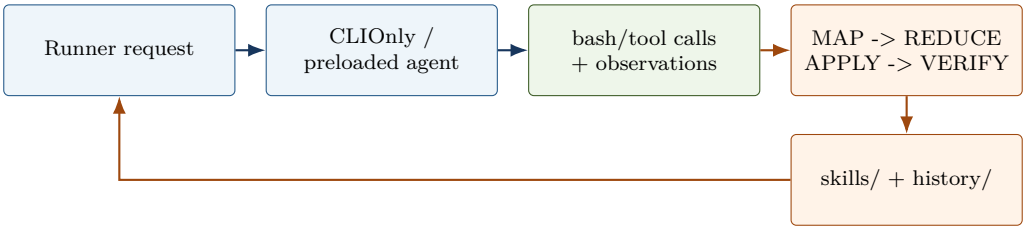
真实运行 `runs/merge-skillopt-real/deepseek-flow-001/` 共 5 turns、5 interactions，平均分和通过率均为 1.0。五个任务覆盖了 SkillOpt 的核心闭环：

任务	真实请求与可观察产物	动作/工具	结果
profile-fact	创建 `/workspace/profile.txt`，写入 name=Lin、language=Chinese	`write_file`	1.0
delayed-use	读取 profile fact，再创建 `greeting.txt`	`write_file`	1.0
config-repair	将 `mode=development` 改为 production，保留其他键	`write_file`	1.0
json-artifact	生成 status/owner/items 的有效 JSON	`write_file`	1.0
llm-judge	一句话总结 owner Lin、status ready、two items	纯文本	1.0

这里的关键不是把 SkillOpt 改造成 Runner，而是把它的 target 行为和 skill 更新阶段分别映射到 `interact` 与 `evolve`；Runtime 同时冻结 Interaction 期间的学习文件，防止未经 barrier 的持久写入。

5 Trace2Skill：把工具轨迹变成可演化 Skill

Trace2Skill bridge 保留原生工具使用方式，但把步骤转换成公共 trace，并在 Turn 边界执行演化：



修复后的真实运行 `runs/merge-trace2skill-real-fixed/deepseek-flow-001/` 为 5 turns、6 interactions，平均分和通过率均为 1.0，首交互通过率 0.8。可观察的典型经历是 delayed-use：agent 第一次错误地把 Windows 临时路径当作容器路径，随后通过 `pwd`、`ls`、`cat` 发现共享 workspace 中的 profile，创建并验证 `greeting.txt`，最终任务通过。该运行同时在状态目录留下每个 Turn 的 `trajectory.json`、`feedback.json`、`evolution.json` 和 skill patch，说明工具轨迹确实进入了 skill 演化链。

6 三者合在一起后的成品状态

评测维度	当前成品证据
统一可替换性	通过 manifest 选择 baseline；Runner 生命周期不随 Hermes、SkillOpt、Trace2Skill 改写。
真实副作用	Hermes L1 与 SkillOpt 产生可验证文件/事件；Trace2Skill 产生真实终端观察与文件结果。
跨回合学习	Hermes 保留 memory/skills；SkillOpt 保留 skill.md/history；Trace2Skill 保留 skills/history，并在 barrier 后演化。
可审计性	每个 Flow 有 summary、trace、usage、状态快照；judge 只消费公开证据。
当前短板	短流任务已能稳定通过；GLM 长流的 iteration limit、记忆激活和结构化状态更新仍导致 L1-Life 严格通过率为 0%。

Hermes L2 还保留了一条独立的 native runtime 证据：`runs/merge-hermes-l2-real/` 中的 BigCodeBench Pandas 可视化 Episode E001/E002 均通过 private verifier，演化记录为 `evolution.completed`。这与 L1 的公开 judge 轨迹是两种不同层级的验证，但都已经进入统一的 Flow/episode 结果目录。

7 结论

Tri-EvoBench 的当前成品是一个可以承载不同 agent 框架的统一评测层：

- Hermes 证明了 Docker、SessionManager、memory/skills 和 L1/L2 verifier 可以被纳入统一生命周期；
- SkillOpt 证明了 target agent 与 Reflect/Aggregate/Clip/Update skill 学习可以在 Flow 边界内运行；
- Trace2Skill 证明了真实工具轨迹可以被转换为公开 evidence，并进入 MAP/REDUCE/APPLY/VERIFY 技能演化；
- 三者都输出相同语义的 Flow/Turn/Interaction/Evolution 结果，允许后续做跨 baseline 比较；
- 目前需要继续优化的是 agent 在长流中的任务完成、记忆激活和结构化动作，而不是再重做 baseline 接入层。