Tri-EvoBench 周度工作进展报告

项目组

2026 年 8 月 28 日

1 本周结论

本周完成了 Hermes L1 真实评测链路的关键修复与端到端复测。最终使用 Docker 隔离环境和 DeepSeek 模型完成 7 个 L1 回合，全部通过，平均分为 0.9214。评测保持了 turn-boundary evolution；每回合 evolution 实际发起一次模型调用，并按工作上限可恢复地结束，而非被禁用。

上周已经以 LLM 跑通基础 L1 与 L2 路径。本周工作的重点不是重复 smoke test，而是消除 Hermes L1 适配、模拟副作用、跨轮评判和工作区上下文中的实际缺口，使结果可复现、可审计。

2 上周基线状态

项目	已有结果	说明
基础 L1 / L2 链路	已跑通	已验证 Docker、LLM 连接、评测 Runner 与 trace 基础链路。
Trace2Skill	5/5 通过，约 664 tokens	真实 Docker + DeepSeek 回归记录位于 runs/merge-trace2skill-real-fixed/。
SkillOpt	5/5 通过，约 4,644 tokens	真实 Docker + DeepSeek 回归记录位于 runs/merge-skillopt-real/。
Hermes L2	SRA E001/E002 通过，约 286,814 runtime tokens / 13 calls	历史真实 L2 结果位于 runs/merge-hermes-l2-real/。

3 本周完成的工程工作

3.1 L1 只读工作区上下文

L1 保持禁用 Hermes 原生工具，所有副作用仍只能经由 Tri-Evo 协议交给 Runner 执行。同时，桥接层受限地注入 `docs/` 与 `data/` 下的 UTF-8 文本快照，排除 `.git`、`state`、`iterations`、缓存与过大文件。该机制解决了分析、润色与翻译任务无法读取基准输入的问题，而不向 agent 开放原生文件写入能力。

3.2 L1 协议与副作用修复

- L1 不再依赖 “available_tools 非空” 判断模式；没有模拟工具的只读回合也会关闭原生工具并采用 L1 工作上限。
- 新增 `TRIEVO_ACTION` 的 `write_file` 解析；文件创建可将完整内容真正写入 sandbox。
- 对携带完整内容的既有 `file.create_file` 协议调用进行兼容归一化，形成可审计的 `write_file` action。
- 协议 prompt 明确规定：澄清回合不得发起依赖该澄清的工具调用；日历调用不得缺失 `calendar_id`、`title`、`start`、`end`。

3.3 跨回合状态与评判修复

- 已审计的 `state_update` 会作为只读持久事实提供给后续 L1 回合，避免模型丢失已确认的日历 ID、输出语言或项目事实。
- LLM judge 现可取得当前 Turn 已发生的 interaction 轨迹，包括先前的澄清文本、事件、工具调用与状态更新；不再只看最终一句回复而误判已发生的澄清。
- 保留 public-trajectory 边界：judge 与 evolution 只接触公开任务、公开事件、公开工具结果和公开状态，不读取私有 oracle 内容。

4 最终 L1 真实回归结果

运行配置：Docker 隔离；Hermes 镜像 `trievo-hermes-merged:0.14`；DeepSeek；总 token 上限 750,000；每个前台 interaction 的模型调用及 evolution 均受限。

回合	分数	交互次数	结果
turn1	0.95	2	通过
turn2	0.95	3	通过
turn3	0.85	2	通过
turn4	0.85	2	通过
turn5	0.95	2	通过
turn6	0.95	1	通过
turn7	0.95	1	通过
总计	0.9214	13	7/7 通过

本次完整运行消耗 329,129 tokens、31 次 API 调用。每个 Turn 的 evolution 使用 1 次 API 调用后触及 `evolution_max_model_calls`，以可恢复的受限结果记录在 trace 中；这符合 “evolution 保持启用且必须受工作上限约束” 的评测要求。

完整 summary 和 human-readable trace 位于：runs/merge-hermes-l1-full-final/l1-session-1/。

5 质量保证与提交

- 本地单元测试：44 项全部通过。
- 已执行 Python 编译检查与 `git diff --check`。
- 本周核心提交：`6e1bbe3 Fix Hermes L1 readonly context and limits`；`f96cf4e Harden L1 protocol execution and judging`。
- API 密钥未写入仓库、日志、报告或提交信息；临时评测 override 与 `runs/` 结果未纳入提交。

6 后续工作

L1 最终回归已达标。下一阶段应基于当前最终代码和镜像重新执行 Hermes L2、SkillOpt 与 Trace2Skill 的真实回归，避免将旧镜像的历史结果当作最终版本结论；同时汇总三套 baseline 的最终可读 trace 与 token 审计。