Tri-EvoBench 周度工作进展报告

项目组 · 2026 年 8 月 28 日

1. 本周结论

本周完成 Hermes L1-Life v2 的 Docker 端到端链路修复与两条 60 回合全量复测。最终使用 GLM-5.3-Flash 完成 120 个 turns；两条流均正常写出 summary，judge 请求无 HTTP 错误，平均 turn 分数分别为 0.1363 和 0.1524。为保证强制思考模型的稳定性，本次临时全量配置采用最低思考档并关闭额外后台 review；evolution barrier 仍逐回合执行并记录为 skipped。

2. 上周基础与本周工程工作

上周已用 LLM 跑通基础 L1/L2。本周将 L1-Life v2 数据包（10 条流、每流 60 turns）放入 benchmarks/l1_life_v2，并完成适配器、状态隔离、模拟工具副作用、跨回合公开轨迹和严格 judge 的工程整合。Hermes Docker manifest 新增 GLM/Z.AI 环境透传；GLM 客户端支持 reasoning_effort=low/medium/high/max，并保留可诊断的 HTTP 错误体。

3. 最终 L1-Life v2 全量结果

流	turns	交互	API calls	平均分	通过率
stream-1	60	62	131	0.1363	0%
stream-2	60	62	139	0.1524	0%
合计	120	124	270	0.1444	0%

两条最终流分别消耗 2,323,736 与 2,501,417 tokens，共 270 次 API calls。所有 120 个 turns 均完成；0% 通过率反映 GLM 在当前 L1-Life 协议下未达到严格满分阈值，不是运行中断或 judge 请求失败。此前的 HTTP 400/1210 已通过 GLM 强制思考参数映射与 judge 输出上限修复。

4. 质量保证与可复现性

本地单元测试 49 项全部通过。最终结果目录为 runs/l1-life-hermes-glm-final2/stream-1/l1_life_stream_1/ 与 runs/l1-life-hermes-glm-final2/stream-2/l1_life_stream_2/；每条目录包含 summary.json、trace.jsonl 和 baseline 状态快照。密钥只通过临时环境变量传入，未写入仓库、日志、报告或提交信息。

5. 后续工作

下一步在相同 GLM 配置下评估 Hermes L2、SkillOpt 与 Trace2Skill，并针对 L1-Life 的低通过率改进协议提示与 agent 的结构化 JSON 产出。